



Classification de tumeurs par expression génétique RNA-Seq

Réalisé par: Nohaila ICHOU & Hajar EL KHALIDI
Encadré par: Mr. El habib BEN LAHMAR & Mme Oumaima GUENDOUL

Introduction & Contexte

Le cancer représente l'une des principales causes de mortalité à l'échelle mondiale, avec plus de 10 millions de décès recensés chaque année selon l'OMS. Le diagnostic précoce et précis du cancer est un enjeu majeur de santé publique. Si l'analyse histologique reste la référence clinique, elle demeure invasive et dépendante de l'expertise humaine. Le séquençage RNA-Seq offre une alternative moléculaire : chaque type tumoral possède une signature d'expression génique unique, exploitable par des algorithmes de Machine Learning.

Conclusion & Perspectives

Le modèle XGBoost atteint 99,12 % de F1-score avec une seule erreur de classification sur 160 patients, validant pleinement la faisabilité d'un diagnostic moléculaire automatisé par RNA-Seq. Les limites restent la généralisation hors cohorte TCGA et la couverture de 5 types de cancers uniquement. Les perspectives incluent l'intégration de données multi-omiques (combiner plusieurs types de données biologiques simultanément), le deep learning, et la classification de sous-types intratumoraux pour une médecine de précision.


Méthodologie

Dataset : Kaggle Gene Expression Cancer RNA-Seq de 801 patients et 20 531 gènes
Outils : HTML, Python, ONNX (Open Neural Network Exchange), Kaggle Notebook
Modèle : XGBoost
Prétraitement : Vérification de la qualité des données, transformation logarithmique (réduction de l'asymétrie), séparation train/test



Résultats

Ce graphique en barres horizontales compare les performances de 5 modèles: XGBoost, Random Forest, SVM (RBF + PCA), Régression Logistique et KNN (k=7). XGBoost est clairement le meilleur classifieur sur ce dataset.



Cette matrice évalue les prédictions sur 160 patients du jeu de test. Une seule erreur sur 160 patients, ce qui confirme les 99 %+ de précision. La seule confusion concerne un patient BRCA (sein) classé à tort comme LUAD (poumon).



Interface

